

AI-CleanChat

Vladyslav Zhadan

ČVUT–FIT

zhadavla@fit.cvut.cz

11. ledna 2025

1 Úvod

V současné době musí uživatelé streamovacích platforem, jako je například Twitch, dodržovat určité zásady této platformy, aby nedocházelo k urážení ostatních uživatelů. Momentálně je tento problém řešen prostřednictvím týmu administrátorů, kteří postupně odstraňují zprávy obsahující nenávistné projevy nebo urážlivý jazyk. Cílem této práce bylo převést část této činnosti na AI model. Ideální by bylo, aby se model dokázal správně přizpůsobit specifickým skupinám uživatelů, přičemž by uživatelé měli možnost označovat zprávy jako škodlivé či neškodlivé, a model by se na základě těchto označení mohl dále přetrénovat.

2 Vstupní data a model

Pro AI model byl vybrán relativně jednoduchý model BERT, který byl fine-tunován pomocí datasetu Hate Speech and Offensive Language. Tento dataset obsahuje rozsáhlý soubor zpráv z platformy Twitter spolu s odpovídajícími kategoriemi, což ho činí ideálním pro naše účely. Délka a formát zpráv na Twitteru jsou velmi podobné těm v Twitch chatu, stejně jako zásady obou platforem, což usnadňuje budoucí fine-tuning.

3 Technologie / Frameworky

Pro komunikaci byl zvolen WebSocket protokol, který umožňuje real-time komunikaci. Frontend byl vytvořen pomocí jednoduché kombinace JavaScriptu, HTML a CSS. Jako HTTP server pro frontend byl použit framework FastAPI. Celá aplikace byla implementována s využitím asynchronních metod. Hlavním problémem bylo volání AI modelu v běžící aplikaci, což bylo vyřešeno spuštěním modelu v samostatném vlákně.

Pro kontrolu semestrální práce by však nebylo praktické model stahovat z Gitu nebo jej trénovat. Proto byla vytvořena dummy verze modelu, která demonstruje funkcionalitu bez nutnosti jeho volání.

4 Výsledky

Hlavním výsledkem je pochopení příčiny, proč streamovací platformy tuto funkcionalitu neimplementují (pro volání modelu je nutný nenulový čas). Kromě toho byla dosažena základní funkcionalita aplikace. Splnění všech původně zamýšlených cílů nebylo možné vzhledem k rozsahu práce, který by vyžadoval více času a zdrojů.

5 Závěr

Jako rozšíření by bylo možné implementovat funkcionalitu pro přetrénování modelu, přizpůsobení různým skupinám uživatelů. Dále by bylo vhodné zaměřit se na optimalizaci výkonu aplikace (modelu) s cílem zvýšit její rychlost a efektivitu. Dále by bylo vhodné zaměřit se na zvýšení pokrytí testů (test coverage).

Bibliografie

Níže uvedené zdroje byly užitečné během vývoje:

- Real Python. Práce s async v Pythonu. online.
[cit. 2025-01-11]
<https://realpython.com/python-async-features>
- FastAPI. Oficiální dokumentace. online.
[cit. 2025-01-11]
<https://fastapi.tiangolo.com/tutorial/>
- Real Python. Tkinter guide. online.
[cit. 2025-01-11]
<https://realpython.com/python-gui-tkinter/>